



CNN, RNN, LSTM

목차

01

CNN의 핵심 가정

- Locality 가정
- Stationarity 가정
- 딥러닝에서의 의미

02

CNN의 장점

- Weight sharing
- 파라미터 감소
- 학습 효율성

03

CNN의 한계

- Receptive field 제한
 - 정보 손실
 - 구조적 원인

04

RNN의 구조와 동작

- Hidden state 개념
- 상태 업데이트
- Gradient 문제

05

RNN의 문제점

- Gradient vanishing
- 장기 의존성 붕괴
- 반복 곱셈 구조

06

LSTM의 해결책

- Cell state 경로
- Gate 메커니즘
- 정보 관리 구조

Locality 가정: 의미 있는 패턴은 공간적으로 가까운 곳에 존재

- 이미지에서 의미 있는 특징들은 인접한 픽셀들 사이에서 형성됨
- 멀리 떨어진 픽셀보다 가까운 픽셀들의 관계가 더 중요함
- 이 가정을 통해 작은 필터로도 효과적인 패턴 인식이 가능함

Stationarity 가정: 패턴은 위치가 바뀌어도 의미 유지

- 같은 패턴이 이미지의 어느 위치에 나타나도 동일하게 인식되어야 함
- 예를 들어 고양이 귀는 이미지 왼쪽에 있든 오른쪽에 있든 같은 특징임
- 이 가정 덕분에 하나의 필터를 전체 이미지에 공유할 수 있음



CNN의 핵심 가정

CNN은 이미지의 공간적 구조를 활용하는 두 가지 핵심 가정에 기반합니다. 이 가정들은 합성곱 연산의 효율성을 뒷받침하며, 딥러닝에서 이미지 처리의 혁신을 가능하게 했습니다.




CNN의 장점

CNN의 두 가지 핵심 가정인 locality와 stationarity는 weight sharing을 가능하게 만듭니다. 이를 통해 CNN은 적은 파라미터로도 강력한 성능을 발휘할 수 있습니다.



Weight Sharing

- Locality와 stationarity 가정이 충족되면 같은 필터를 여러 위치에 재사용 가능
- 하나의 필터가 이미지 전체를 순회하며 동일한 가중치로 패턴 탐지
- 위치에 관계없이 동일한 특징을 인식할 수 있는 구조



파라미터 수 감소

- 전통적인 fully connected layer에 비해 파라미터 수가 극적으로 감소
- 예: 100x100 이미지를 처리할 때 3x3 필터는 9개 파라미터만 필요
- 메모리 사용량 감소와 overfitting 위험 완화



학습 효율성 향상

- 적은 파라미터로 인해 학습 속도가 빨라짐
- 더 적은 데이터로도 효과적인 학습 가능
- 일반화 성능이 향상되어 새로운 데이터에 대한 예측력 증가



CNN의 본질적 한계

CNN의 locality 가정은 장점이자 동시에 한계입니다. 공간적으로 가까운 패턴에 집중하는 구조는 전역적 정보를 파악하는 데 제약이 있으며, 네트워크가 깊어질수록 이러한 문제가 누적됩니다.

CNN은 강력하지만 구조적 제약으로 인한 한계가 존재합니다

Receptive Field 제한

- 각 레이어의 필터는 제한된 영역만 볼 수 있음
- 초기 레이어는 매우 작은 영역의 정보만 처리
- 전체 이미지의 맥락을 파악하려면 많은 레이어가 필요
- 멀리 떨어진 픽셀 간의 관계를 직접 학습하기 어려움

정보 손실 발생

- 레이어를 거칠 때마다 pooling으로 공간 해상도 감소
- 세밀한 위치 정보가 점진적으로 손실됨
- 깊은 네트워크에서는 초기 입력의 디테일이 희석됨
- 복원이 필요한 작업에서 어려움 발생

구조적 원인

- Locality 가정 자체가 전역 정보 처리를 제한
- 합성곱 연산의 지역적 특성이 근본 원인
- 깊이를 늘려도 receptive field 확장에는 한계
- 이는 CNN 구조의 본질적 trade-off

Hidden State: 과거 정보를 압축한 벡터

- Hidden state는 이전까지의 모든 입력 정보를 요약한 벡터
- 시퀀스의 과거 맥락을 현재 시점으로 전달하는 메모리 역할
- 고정된 크기의 벡터에 가변 길이의 정보를 압축
- 이를 통해 순차적 데이터의 시간적 의존성을 모델링

매 시점마다 상태를 업데이트하는 방식

- 현재 시점 t 에서 이전 hidden state $h(t-1)$ 과 현재 입력 $x(t)$ 를 받음
- 두 정보를 결합하여 새로운 hidden state $h(t)$ 를 생성
- 이 과정이 시퀀스의 모든 시점에서 반복됨
- 각 시점의 출력은 현재 hidden state를 기반으로 계산됨




RNN의 기본 구조

RNN은 순차 데이터를 처리하기 위해 hidden state라는 개념을 도입했습니다. 이 상태 벡터는 과거의 모든 정보를 담고 있으며, 매 시점마다 새로운 입력과 결합되어 업데이트됩니다.




RNN의 동작 원리

RNN은 매 시점마다 이전 상태와 현재 입력을 결합하여 새로운 상태를 생성하는 순차적 구조로 동작합니다.




이전 상태와 현재 입력의 결합

- Hidden state는 과거 정보를 압축한 벡터입니다.
- 매 시점마다 이전 hidden state와 현재 입력값을 함께 받아들입니다.
- 두 정보를 결합하여 현재 시점의 표현을 만들어냅니다.



새로운 상태 생성 과정

- 이전 상태와 현재 입력이 가중치 행렬과 곱해집니다.
- 활성화 함수를 통과하여 새로운 hidden state가 생성됩니다.
- 이 과정이 매 시점마다 반복적으로 수행됩니다.




순차 데이터 처리의 메커니즘

- 시간 순서대로 데이터를 하나씩 처리합니다.
- 각 시점의 출력은 다음 시점의 입력으로 전달됩니다.
- 이를 통해 시계열 정보를 순차적으로 학습할 수 있습니다.



RNN의 치명적 문제


RNN은 반복적인 곱셈 구조로 인해 gradient가 점점 작아지면서 장기 의존성을 학습하지 못하는 치명적 한계를 가지고 있습니다.





LSTM의 핵심 아이디어

LSTM은 RNN의 gradient vanishing 문제를 해결하기 위해 cell state라는 거의 선형에 가까운 경로를 도입한 구조입니다.



Cell State: 거의 선형에 가까운 경로

LSTM의 가장 핵심적인 요소는 cell state입니다.

- Cell state는 정보가 거의 변형 없이 흐를 수 있는 고속도로 같은 경로입니다.
- 복잡한 비선형 변환 없이 선형에 가까운 연산만 수행됩니다.
- 이를 통해 gradient가 먼 과거까지 직접 전달될 수 있습니다.

Gradient가 직접 흐를 수 있는 구조

Cell state의 선형 구조 덕분에 RNN의 문제가 해결됩니다.

- Gradient가 cell state를 따라 직접 역전파될 수 있습니다.
- 반복적인 곱셈으로 인한 gradient 소실이 방지됩니다.
- 장기 의존성을 효과적으로 학습할 수 있게 됩니다.
- 이것이 LSTM의 설계 철학입니다.

Gate의 본질: 정보를 계산하는 것이 아닌 관리하는 장치

- Gate는 0과 1 사이의 값을 출력하여 정보의 통과 여부를 결정합니다.
- 정보를 새로 만들어내는 것이 아니라 기존 정보를 선택적으로 유지하거나 제거합니다.
- 이를 통해 cell state를 효율적으로 관리합니다.
- 기억을 연산하는 것이 아닌 관리하는 구조입니다.

Forget Gate와 Input Gate의 역할

- Forget gate는 cell state에서 불필요한 정보를 삭제하는 역할을 합니다.
- 어떤 정보를 버릴지 결정하여 cell state를 정리합니다.
- Input gate는 새로운 정보를 cell state에 추가하는 역할을 합니다.
- 현재 시점의 중요한 정보만 선택적으로 저장합니다.




LSTM Gate 메커니즘

LSTM의 gate들은 정보를 계산하는 장치가 아니라 선택적으로 유지하거나 버리는 관리 장치입니다.




LSTM Gate 메커니즘

Output gate는 cell state에서 어떤 정보를 외부로 노출할지 결정하며, 전체 gate 시스템은 기억을 관리하는 구조로 작동합니다.




Output Gate

- Output gate는 cell state 중 어떤 부분을 외부로 출력할지 결정합니다.
- 모든 정보를 노출하지 않고 필요한 부분만 선택합니다.
- 현재 시점에 필요한 정보만 hidden state로 전달합니다.



기억 관리 구조

- LSTM은 기억을 연산하는 것이 아니라 관리하는 시스템입니다.
- Gate들이 협력하여 정보의 흐름을 제어합니다.
- Cell state는 장기 기억 저장소 역할을 합니다.



선택적 정보 유지 및 제거

- 각 gate가 독립적으로 정보의 유지와 제거를 판단합니다.
- 중요한 정보는 오래 유지되고 불필요한 정보는 빠르게 제거됩니다.
- 이를 통해 효율적인 장기 의존성 학습이 가능합니다.



CNN

- 공간적으로 가까운 패턴을 효과적으로 인식합니다.
- Weight sharing으로 파라미터를 크게 줄입니다.
- Receptive field 제한과 정보 손실이라는 한계가 있습니다.




RNN

- 순차 데이터를 시간 순서대로 처리합니다.
- Hidden state로 과거 정보를 압축합니다.
- Gradient vanishing으로 장기 의존성 학습에 실패합니다.



LSTM

- Cell state라는 선형 경로로 gradient를 직접 전달합니다.
- Gate 메커니즘으로 정보를 관리합니다.
- 장기 의존성 문제를 효과적으로 해결합니다.



요약

- 각 모델은 고유한 가정과 구조를 가집니다.
- 장점과 한계를 이해하면 적절한 모델 선택이 가능합니다.
- 구조적 설계가 성능을 결정합니다.

정리 및 마무리